


CondruLytics

Analyse, prédiction et visualisation des résultats
du Challenge Condrusien
de 2006 à 2025

Michaël Mestré

Université de Namur – Faculté d'Informatique

Juin 2026



Le Challenge Condrusien : une saison de courses locales

Contexte

- ▶ Challenge de course à pied amateur dans le Condroz liégeois.
- ▶ Environ une vingtaine d'organisations par saison.
- ▶ Plusieurs formats : petite distance, grande distance, parfois trail.
- ▶ Des classements publiés après chaque course.

logo.png

Chaque résultat est lisible, mais sa comparaison est difficile.

Besoin : comparer des performances

Les classements sont consultables, mais ils répondent mal aux questions d'un coureur.

- ▶ Ai-je progressé, ou la course était-elle plus favorable ?
- ▶ Comment comparer un 6 km roulant et un 12 km vallonné ?
- ▶ Ai-je mieux couru que d'habitude par rapport aux autres ?
- ▶ Quel temps aurais-je pu faire sur une course non courue ?

Besoin

Passer d'une lecture de classement à une lecture comparative, personnelle et contextualisée.

Classement



Indicateur comparable



Analyse coureur

CondruLytics

transforme des classements historiques en
**données structurées, indicateurs de performance et simulations
interprétables.**

- ① Données de départ
- ② Pipeline ETL
- ③ Nettoyage et correction des coureurs
- ④ Feature engineering et prédiction
- ⑤ Application Streamlit et démonstration
- ⑥ Limites et perspectives

Données disponibles

588

fichiers PDF

114 761

résultats nettoyés

566

courses


24 264

noms normalisés

Lecture

Le volume est raisonnable, mais la difficulté vient de l'hétérogénéité historique et de la qualité variable des extractions.

Pipeline général



Parsing : plusieurs stratégies selon les années

- ▶ `Parser2006_2007`
- ▶ `Parser2008_2016`
- ▶ `Parser2017_2024`
- ▶ `Parser2025`

Chaque fichier est converti en données tabulaires puis sauvegardé en Parquet.

Choix technique

Un *ParserFactory* sélectionne automatiquement la stratégie adaptée au fichier analysé.

Nettoyer sans fusionner à tort

Problème

Une même personne peut apparaître avec plusieurs variantes de nom.


- ▶ accents, tirets, apostrophes ;
- ▶ fautes de frappe ;
- ▶ bruit d'extraction PDF ;
- ▶ homonymes possibles.

Principe

Correction prudente : accepter seulement les rapprochements à confiance élevée.

- ▶ similarité de nom ;
- ▶ sexe compatible ;
- ▶ vitesse moyenne cohérente ;
- ▶ pas de doublon sur une même course.

Correction des coureurs en deux passes



Compromis

Il vaut mieux conserver quelques doublons résiduels que fusionner deux coureurs différents.

Pourquoi une performance relative ?

Même coureur, contextes différents

Une allure brute ne suffit pas pour comparer deux courses.

- ▶ Le dénivelé peut ralentir une course.
- ▶ La nature du sol change l'effort réel.
- ▶ La météo peut modifier fortement le résultat.
- ▶ La distance influence aussi l'allure possible.

$$z = \frac{v - \mu_{\text{course}}}{\sigma_{\text{course}}}$$

$$\text{Indice} = 100 + 10z$$

Idée

Comparer le coureur aux participants de la même course, qui partagent globalement les mêmes conditions.

Hypothèse de travail

Le niveau global du plateau est considéré comme suffisamment comparable entre courses et éditions pour que cet écart relatif soit informatif.

Variables utilisées par le modèle

Historique coureur

- ▶ nombre de courses précédentes ;
- ▶ vitesse moyenne et meilleure vitesse ;
- ▶ performance récente sur 3 courses ;
- ▶ jours depuis la dernière course.

Contexte course

- ▶ distance ;
- ▶ mois ;
- ▶ jour de l'année ;
- ▶ moyenne et dispersion de la course.

Découpage temporel : entraînement sur les années passées, test sur 2025.

Résultats de la régression

Jeu	n	MAE z	R^2 z	MAE temps
Entraînement	74 589	0,331	0,771	217 s
Test 2025	5 627	0,335	0,778	200 s

Interprétation

Le modèle capte une tendance générale sans surapprentissage évident, mais la prédiction reste une aide à l'analyse plutôt qu'une vérité sportive.

Temps réel vs temps prédit

temps_reel_vs_predit_2025.png

Personas : deux usages complémentaires

Claire, coureuse loisir

- ▶ Comprendre ses résultats sans vocabulaire statistique.
- ▶ Savoir si elle progresse au fil des courses.
- ▶ Identifier les courses où elle a mieux couru que d'habitude.

Marc, coureur régulier

- ▶ Comparer ses performances entre distances.
- ▶ Se situer par rapport aux autres coureurs.
- ▶ Estimer un temps probable sur une course non courue.

L'application doit transformer les classements en réponses actionnables.

Des besoins aux vues de l'application

Besoin	Vue	Réponse apportée
Comprendre le challenge	Vue d'ensemble	années, courses, volumes
Comparer une course	Vue course	classement, catégories, écart attendu/réel
Suivre sa progression	Vue coureur	indice de performance et historique
Se projeter	Simulation	temps estimé sur une course non courue

Choix de conception

Les visualisations sont pensées autour de questions de coureurs, pas seulement autour des tables de données disponibles.

Démonstration live

Parcours prévu

- ① Vue d'ensemble : période, courses et volume de résultats.
- ② Vue course : classement, catégories, temps attendu.
- ③ Vue coureur : évolution de l'indice de performance.
- ④ Simulation : temps estimé sur une course non courue.

La démo montre le passage de la donnée structurée à un usage concret.

Captures disponibles en backup en cas de souci de démonstration.

- ▶ Les PDF historiques ont été structurés.
- ▶ Les noms, courses, temps et catégories ont été harmonisés.
- ▶ Un indice de performance rend les courses comparables.
- ▶ L'application permet l'exploration et la simulation.

- ▶ Les PDF restent hétérogènes et peuvent entraîner des erreurs de parsing.
- ▶ L'identification des coureurs repose surtout sur le nom corrigé.
- ▶ La simulation est rétrospective : la course cible doit déjà exister dans l'historique.
- ▶ Le modèle ne dispose pas de variables comme le dénivelé ou la météo.

Perspectives

- ▶ Ajouter des tests automatisés sur parsing, nettoyage et transformations.
- ▶ Améliorer l'identification des coureurs.
- ▶ Estimer des courses futures à partir d'éditions précédentes ou de courses comparables.
- ▶ Enrichir les données avec des informations de parcours.

Au départ : des classements PDF dispersés.

À l'arrivée : une base structurée, un modèle de performance et une interface interactive.

CondruLytics rend visible l'histoire sportive du Challenge Condrusien.


Questions ?

Backup : vue d'ensemble



vue_ensemble.png

Backup : vue course




course_classement.png

Backup : vue coureur



coureur_profil.png

Backup : simulation rétrospective



coureur_simulation.png